FREEDOM

ДЛЯ КОМАНДЫ · ПОДГОТОВКА К ЗАЩИТЕ

Freedom CQA: как защищаемся

План на 8–10 минут, кто что говорит, путь по кликам, цифры наизусть, 15 главных вопросов и чего не говорить. Полные ответы: `pitch/jury-qa.md`.

Формат (организаторы, вс 09:30): 8–10 минут вместе с вопросами. Показать весь цикл: настройка чек-листа → получение диалогов → оценка → результаты → апелляция → ручная переоценка. Командам из топ-10 дадут прогнать пару транскриптов при жюри.

1. План защиты по минутам

Время	Шаг	Говорит	Что показать и сказать
0:00–0:40	**Команда и проблема**	Тайр	Кто мы, что решаем: ручной QA видит малую долю разговоров, оценки расходятся. Одна фраза о решении.
0:40–1:30	**Настройка чек-листа**	Дамели	/admin/ → Чек-лист: 8 пунктов, вес, тип ответа, N/A. Добавить или изменить пункт, сохранить версию.
1:30–2:10	**Получение диалогов**	Амина	Загрузка диалогов: набор по group_id (FBroker / Swap) или свой транскрипт. API организаторов идёт через наш сервер.
2:10–3:40	**Оценка вживую**	Назар	Диалог → «Оценить заново»: логотип заполняется, 3 независимые оценки, голосование, баллы считает код. Пока идёт ~30 с, объяснить конвейер.
3:40–4:40	**Результаты**	Назар	Итог, «Как посчитан итог», грубая ошибка, клик по цитате → реплика в расшифровке, пример N/A. Обзор: все грубые ошибки с причинами, фильтр по языку.
4:40–5:40	**Апелляция → решение**	Дамели	«Оспорить» с комментарием → роль «Проверяющий» → изменить ответ с причиной → итог пересчитан, исходная оценка в карточке.
5:40–6:20	**Точность и цена**	Тайр	95,4 % / 96,4 % / 97,3 %, 7 из 7 грубых; контроль FBroker 10 чатов за 67 с, $0,061; ≈ $0,006 за чат.
6:20–10:00	**Вопросы жюри**	все	Отвечает владелец темы: модель и точность — Назар, интерфейс — Дамели, данные и аудит — Амина, продукт и интеграция — Тайр.

Роли — предложение по зонам ответственности; поменяйте, если договоритесь иначе.

2. Путь по кликам

Вход	https://freedom-cqa.vercel.app/admin/ · код `freedom-agent`. При первом входе запустится тур «Как пользоваться»: его можно пройти или закрыть Esc.
Сценарий проверки	На «Обзоре» панель «Для жюри · Сценарий проверки» ведёт по всем 6 шагам в один клик каждый.
Свой транскрипт	Загрузка диалогов → «Вставить текст» (строки «Клиент: …», «Оператор Арман: …») → «Оценить AI-агентом». Чат ≈ 30 с. Звонок может идти больше минуты: вживую показываем чат.
SWAP	Загрузка диалогов → «Набор по group_id» → Swap. С официальным чек-листом ответ из кэша (так и написано в карточке). Чтобы показать живую оценку, нажать «Оценить заново».
Замена критерия	Чек-лист → изменить текст/добавить пункт → сохранить → «По ID» 1–2 чата ≈ 35 с. Смена только веса пересчитывается мгновенно и бесплатно.
Оператор ↔ оператор	Если в тексте два оператора, карточка покажет «Операторы: Арман → Айгерим», внутренние реплики идут как контекст. Без клиента — «нет клиента», оценка не применяется.

Если вопросы перебивают

- Если просят «покажите» — сначала показываем, потом объясняем.

- Живую оценку делаем на **чате**, не на звонке: чат ≈ 30 с, звонок может идти больше минуты.
- Смена веса пересчитывается мгновенно — хороший быстрый ответ на «измените чек-лист».
- Для замены критерия — «По ID» на 2 чата, ≈ 35 с.
- Пока идёт оценка, рассказываем конвейер из раздела 3: 30 секунд как раз хватает.

3. Цифры наизусть

Что	Цифра	Источник
Модель	OpenAI **GPT-6 Luna**, прямой OpenAI API, промпт **eval-v5.3**, 3 ответа и голосование	`lib/evaluator.js`, README
Точность, все 19 gold-диалогов (152 ответа)	**95.4%** точных совпадений, 98.7% с допустимыми альтернативами	`eval/runs/2026-11-07T16-05-00Z-v53-report.md`
Точность, 7 отложенных диалогов (56 ответов)	**96.4%** / 100%	там же
Только чаты gold (18 чатов, 144 ответа)	97.2% (95% CI 93–99), к 0.96	`eval/runs/agreement-v53.md`
Слепая разметка, 24 других чата	**97.3%** (180 из 185 ответов, где оба разметчика согласны)	`eval/blind/blind-24.json`
Потолок: два разметчика между собой	**96.4%** (185 из 192), мы с каждым по 95.3%	README «Beyond percent agreement»
Грубые ошибки на gold	**7 из 7 найдены, 0 ложных**	v5.3 report
Грубые ошибки на DEV	8 из 65 диалогов	v5.3 report §4
По языкам (gold, strict)	EN 100% (40 ответов) · KZ 97.5% (40) · RU 91.7% (72)	README
Самый слабый критерий	C6 «Управление диалогом»: 83.3% на чатах gold, к 0.68; у двух разметчиков между собой к 0.61	agreement-v53
Стоимость	≈ **$0.006 за чат**, ≈ $0.016–0.018 за звонок, в среднем $0.007 по 65 DEV	README «Models, cost, latency»
Скорость	чат ≈ **30 с** (p50 27–32 с, p95 45–62 с), звонок ≈ 2–2.5 мин, из кэша ≈ 20 мс	там же
Контрольная репетиция	10 новых чатов за **79 с**, $0.064	v5.3 report §6
Контроль FBroker (вс, 10:52)	10 чатов за **67 с**, **$0.061**, 0 сбоев; средний балл 73.44; грубые 2 из 10 (p2-ru-004, p2-kz-003); «3 из 3» в 72 из 80 ответов	`eval/runs/2026-11-08T05-52-46-698Z-FBroker.json`, `results/prod/results.json`
Набор SWAP	3 чата (RU, KZ, EN), оценены заранее с официальным чек-листом, $0.019; после замены критерия кэш не срабатывает	`data/datasets/Swap.json`, `eval/runs/2026-11-08T05-54-28-257Z-swap-warm-Swap.json`
Живой тест API (вс, 09:56)	33.7 с, $0.0064, все 3 ответа совпали по всем 8 критериям	README «Evaluate your own transcript»
Масштаб (арифметика)	10 000 диалогов ≈ $70	README

Пересчёт после апелляции или смены веса	**$0**, считает код	`prototype/scoring.js`
Сравнение моделей (тот же промпт v1, 19 gold)	Luna 86.2% vs Claude Haiku 5.5 75.7%; ошибка итога 7.83 vs 14.06 балла	`docs/research/our-experiments.md` §4
Open-weights модель (тот же v5.3, те же 39 чатов)	Qwen 3.8 27B: gold 94.1% vs Luna 97.1%; грубые 7/7 у обеих; $0.034 за чат, 61 с	`eval/runs/agreement-qwen38-27b.json` (ветка `c/33-metrics-confidence-qwen`)
Путь версий (все gold, strict)	макет на ключевых словах 61.8% → v1 86.2% → v4 91.4% → v5.1 96.1% → v5.3 95.4%	our-experiments, README
Средний балл операторов DEV	79.56 (медиана 92.31, от 20 до 100)	`results/dev/results.json`
C7 «Завершение» = «нет»	45 из 60 DEV-чатов (буквальное чтение)	README, `results/dev/results.json`
N/A на DEV-чатах	C2 в 40 из 60, C3 в 53 из 60, C7 в 4, C4 в 1	`results/dev/results.json`
Где теряются баллы (DEV, вес до перераспределения)	C7 230 · C5 195 · C6 171 · C4 160 · C2 150 · C3 80 · C1 40	`results/dev/results.json`
Траты на работу над v5	$1.42 всего	README

4. 15 вопросов, которые спросят почти наверняка

1.1 «Какая модель и почему именно она?»

Ответ: OpenAI GPT-6 Luna через прямой API. Выбрали измерением, не по имени. Один и тот же промпт на 19 размеченных диалогах: Luna дала 86.2% точных совпадений, Claude Haiku 5.5 — 75.7%. Ошибка итогового балла 7.8 против 14.1. И Luna дешевле. Дальше за сутки было семь версий промпта, от v1 до v5.3, каждую мерили на тех же метках.

Показать: README → «How we got here», график истории точности.

Если дожмут («почему не флагман?»): флагманы не мерили. Мы уже на уровне согласия двух независимых разметчиков между собой (96.4%), дальше рост упирается в разметку, а не в модель. Модель меняется одной переменной `CQA_EVAL_MODEL`.

1.2 «Сколько стоит одна оценка?»

Ответ: около $0.006 за чат, это три вызова модели плюс редкий повторный вызов, если ответ не прошёл проверку. Звонок дороже, $0.016–0.018, он длиннее. В среднем по всем 65 DEV — $0.007. Десять тысяч диалогов — примерно $70. Пересчёт после апелляции или смены веса бесплатный: это код, модель не вызывается.

Показать: карточка диалога → строка запуска «модель · время · стоимость».

1.3 «Насколько точно? С чем вы сравниваете?»

Ответ: экспертной разметки DEV нам не дали, поэтому сделали три проверки.

- Своя разметка 19 диалогов, 152 ответа: 95.4% точных совпадений. На 7 отложенных диалогах, под которые не правили промпт, — 96.4%.
- Две независимые слепые разметки ещё 24 чатов. Разметчики видели только чек-лист и ответы организаторов. С их общим мнением совпадаем на 97.3%.
- Потолок: сами разметчики между собой совпадают на 96.4%. То есть наша система совпадает с каждым примерно так же часто, как они друг с другом.

Грубые ошибки: 7 из 7, ложных срабатываний ноль. Настоящий тест — ваши 10 контрольных чатов, по ним меток у нас нет.

Показать: README → «Accuracy», таблица с каппой.

1.4 «Кто размечал gold? Вы не подогнали систему под свою же разметку?»

Ответ: черновик меток сделал AI-агент, каждую метку проверил человек из команды. Отдельный аудит перечитал все 19 диалогов по чек-листу: 84 правки полноты (доказательства, пояснения), ни один ответ не поменялся, все 7 грубых ошибок подтвердились. Против подгонки четыре вещи:

- Разбили gold на 12 для настройки и 7 отложенных и зафиксировали это до первого запуска v5 (`docs/playbook/split.md`).
- Правило принятия новой версии записали заранее: отложенные и слепые не должны упасть, грубые ошибки 7/7 без ложных.
- Слепая разметка сделана отдельными сессиями модели другого семейства (Claude), наш оценщик — GPT.
- Для 18 неразмеченных чатов ожидания записали до запуска v5: v5.3 совпала 72 из 72.

Версию v5.2 это правило отклонило: на слепых она выиграла 2 ответа, на отложенных проиграла 2.

Если дожмут: честно, отложенные частично видели: три правки v5.3 сделаны после того, как черновик ошибся на двух отложенных диалогах. Поэтому мы опираемся ещё и на слепую разметку и на заранее записанные ожидания.

1.5 «Как вы гарантируете, что модель не выдумывает доказательства?»

Ответ: модели мы не верим на слово. После каждого ответа код проверяет: номер реплики существует, цитата совпадает с текстом этой реплики, у каждого «да», «нет» или балла есть ссылка, N/A только там, где чек-лист его разрешает. Если что-то не так — один повторный вызов. Если и он неполный — ошибка, а не полрезультата. Интерфейс показывает настоящую реплику из транскрипта, а не цитату модели. На gold: 0 неверных ссылок из 190, попадание доказательств 99.1%.

Показать: карточка → клик по снижению → транскрипт прокручивается и подсвечивает реплику.

1.6 «Почему баллы считает не модель?»

Ответ: модель хорошо читает и плохо считает. Она выбирает только ответ и реплику. Веса, шкалы, перераспределение N/A и округление делает одна чистая функция `prototype/scoring.js`. Её используют интерфейс, API, экспорт результатов и наш замер точности. Итог воспроизводим, после апелляции пересчитывается мгновенно и бесплатно. Модель в итог не лезет вообще: в ответе API нет баллов.

1.7 «Как работает N/A и перераспределение веса?»

Ответ: N/A ставится, только если критерий его разрешает и условие выполнено. Вес N/A-критериев убирается, итог считается от оставшегося веса и нормируется к 100. Пример: чат p1-ru-001. C2 и C3 — N/A (запрос понятный, данные счёта не нужны), уходит 35 веса. C7 — «нет»: «Пожалуйста. Хорошего вечера!» без итога и без предложения помощи. Набрано 60 из 65 применимых → 92.31. Округляем один раз, итог, половина вверх до двух знаков.

Показать: карточка p1-ru-001, блок «как считается итог».

Если дожмут («а если всё N/A?»): итог не рассчитывается, `total: null`, как в чек-листе.

1.8 «Покажите все диалоги с грубыми ошибками и объясните почему»

Ответ: Обзор → «Грубые ошибки» или Диалоги → фильтр «Грубые ошибки». На DEV их 8 из 65. Три вида по чек-листу: оскорбление клиента, предложение платной услуги в обход компании, раскрытие конфиденциальных данных. Раскрытие данных счёта до идентификации у нас = C3 «нет» и грубая ошибка: организаторы оставили C8 на наш выбор (#2814), а в чек-листе раскрытие конфиденциальной информации прямо записано в грубые.

Показать: список с репликой оператора и объяснением у каждого.

Если дожмут («почему грубая ошибка не обнуляет итог?»): в чек-листе C8 «без баллов» и «отметьте отдельно». Мы так и делаем: красный флаг рядом с итогом. Если Freedom захочет обнулять — это политика, её можно добавить в функцию подсчёта.

1.9 «Почему C7 "нет", если оператор попрощался?»

Ответ: организаторы дважды ответили «перечитайте чек-лист» (#2814, #3024). Там написано: подвёл итог **или** предложил помощь **и** попрощался. «Пожалуйста. Хорошего дня!» — только прощание. Это наша самая большая ставка: на DEV так выходит «нет» в 45 из 60 чатов. Если ваши эксперты читают мягче, правило живёт в одной функции `closingAnswer()`, переворачивается за минуту.

1.10 «Замените критерий. Что произойдёт?»

Ответ: чек-лист — это данные (JSON), а не код. В редакторе меняем текст, тип, вес, шкалу или N/A и сохраняем — это новая версия. Если поменяли только вес, итоги пересчитываются сразу из тех же ответов модели. Если поменяли смысл критерия, нужны новые ответы модели: окно «Что переоценить» → «Все», «Загруженные» или «По ID». Два чата ≈ 35 секунд. Наши встроенные правила для C2, C3, C4, C7, C8 автоматически отключаются для изменённого критерия, и модель судит по его новому тексту.

Показать: Чек-лист → изменить критерий → «По ID» → сохранить → открыть карточку.

1.11 «Оцените этот транскрипт сейчас. Докажите, что это не заготовка»

Ответ: Загрузка диалогов → «Вставить текст» → «Оценить AI-агентом». Около 30 секунд. В карточке строка: модель, время, стоимость и пометка «новый запрос к модели» или «ответ из кэша». Новый текст никогда не бывает в кэше: ключ кэша — модель, версия промпта, весь транскрипт и весь чек-лист. Поменяйте одно слово — будет новый вызов.

Показать: запустить, показать таймер и строку запуска.

Если дожмут: можно то же самое через API: `POST /api/evaluate` с вашим JSON, пример в README.

1.12 «Казахский работает?»

Ответ: да. Правила одни для трёх языков и описывают поведение, а не слова: «поздоровался на языке клиента и представился», а не список фраз. В playbook для каждого критерия есть казахские формулы («Сәлеметсіз бе», «менің атым…»). На gold KZ 97.5% на 40 ответах. Честно: это 5 диалогов, разница с другими языками в пределах шума. Русское название пункта меню в казахском ответе («Меню → Пополнить») мы не считаем ошибкой: так выглядит само приложение. Казахский пример, вставленный утром вживую: 24 секунды, итог 100.

Показать: Загрузка диалогов → «Пример KZ».

1.13 «Как вы оцениваете звонки?»

Ответ: та же логика, адаптированная к речи, как сказали организаторы. Оцениваем по выданным транскриптам и не снижаем оператору за искажённые распознаванием слова. C1 на звонке без записанного приветствия — N/A (#2978). В карточке звонка дорожки по спикерам и плеер, клик по доказательству перематывает запись на это место. Ссылки на mp3 у организаторов живут около часа, поэтому плеер идёт через наш `/api/audio`. Дополнительно критерий c09 «Тон и подача речи» — его слушает модель Gemini по самой записи. В официальный файл результатов он не попадает.

Показать: Диалоги → p4-ru-001.

1.14 «Где ваша система ошибается чаще всего?»

Ответ: назовём сами:

- C6 «Управление диалогом» — шкала на суждение. 83.3% на чатах gold, каппа 0.68. Но и два независимых разметчика между собой там дают каппу 0.61, это трудный критерий для всех.
- C7 — ставка на буквальное чтение.
- C4 на передаче специалисту может быть щедрее экспертов: «корректный следующий шаг» мы даём на верхнюю ступень.
- Выборки маленькие: 56 отложенных ответов, один ответ = 1.8 процентного пункта.

Где модель не уверена, это видно в карточке: «2 из 3 · проверьте».

1.15 «Можно без OpenAI? Банку нельзя отдавать данные наружу»

Ответ: да. Все вызовы идут через один роутер `lib/llm.js`. `local:<model>` подключает любой OpenAI-совместимый сервер внутри контура. Проверили open-weights модель Qwen 3.8 27B (помещается на одну GPU) на тех же 39 чатах с тем же промптом: 94.1% против 97.1% у Luna на gold, грубые ошибки те же 7 из 7. Проигрыш 1–3 пункта, в основном на шкалах C4 и C6. Пробовали и AlemLLM (хостинг в Казахстане): сервер не соблюдает JSON-схему, нужен адаптер ответа, сделаем после контроля.

5. Каверзные вопросы

В: Ваша точность 95% на собственной разметке ничего не значит.

О: согласны, что это не экспертная оценка. Поэтому мы не останавливаемся на ней: слепая разметка другой моделью без нашего playbook даёт 97.3%, заранее записанные ожидания на нетронутых чатах — 72 из 72. И сами разметчики между собой не выше 96.4%. Экспертную цифру покажет ваш контроль, мы её ждём.

В: Модель согласна с разметкой, которую сделала другая модель. Это круговая порука.

О: риск есть, поэтому разметчики — другого семейства моделей и без доступа к нашему playbook и ответам. А gold проверял человек. Мы называем это проверкой согласованности, а не истиной.

В: 97% совпадений — потому что почти всё N/A и «нет»?

О: частично да, поэтому мы считаем каппу. На трудных критериях каппа ниже: C6 0.68, C4 0.91. Мы показываем таблицу по каждому критерию, а не одну общую цифру.

В: Почему вы приняли v5.3, если на всём gold она хуже v5.1 на один ответ?

О: правило принятия смотрит на отложенные и слепые, а не на весь gold, где мы настраивались. На отложенных v5.3 лучше (54 против 53), на слепых лучше (180 против 179), грубые не хуже. Правило записали заранее и следовали ему, даже когда цифра «на всём» выглядела хуже.

В: У вас буквальное чтение C7 — вы специально занижаете операторов?

О: нет, мы следуем тексту чек-листа после двух ответов организаторов «перечитайте чек-лист». Это наше решение, оно записано, и мы честно называем его ставкой. Переворачивается одной функцией.

В: А если оператор попрощался и сказал «обращайтесь»?

О: «обращайтесь» — предложение помощи, вместе с прощанием это «да».

В: Что если транскрипт содержит ошибку организаторов?

О: не выдумываем факты. Если реплика непонятна, оператору не снижаем за распознавание, сомнение пишем в объяснении, решает человек.

В: Ваша система — это просто промпт к ChatGPT.

О: модель — одна из восьми частей. Остальное — код и процесс: факты до вердикта, проверка доказательств с повтором, правила там, где чек-лист однозначен, голосование трёх ответов, детерминированный подсчёт, кэш, апелляция, и измерение каждой версии по правилу, записанному заранее. Модель заменяется одной переменной, например на Qwen, и система продолжает работать: 94% против 97%.

В: Почему не оценить все 65 DEV при нас?

О: можем, все 65 уже оценены; заново с нуля — это около 9 минут и $0.45. Быстрее показать 2–3 новых диалога: «Вставить текст».

В: Что если мы дадим диалог на узбекском?

О: заявлены RU, KZ и EN, другие языки не проверяли. Модель скорее всего справится, но цифр точности для него нет.

В: Очень длинный диалог — 500 реплик?

О: сервер принимает до 600 реплик. Длинный диалог дольше и дороже: звонки у нас — до 2.5 минут. Лимит функции — 300 секунд, голосуем по ответам, которые пришли за 240.

В: Кто виноват, если система поставила оператору грубую ошибку, а он не виноват?

О: система ничего не решает сама: это подсказка проверяющему с репликой. Оператор оспаривает, решает человек. Мы отклонили v3 именно за ложные грубые ошибки.

В: Почему не поставить порог уверенности и не отдавать неуверенные человеку автоматически?

О: доля согласных ответов уже есть в ответе API и в карточке. Маршрутизация «2 из 3 → в очередь проверяющего» — одна строка в фильтре, её логично добавить в пилоте.

6. Чего не говорить

- Не говорить «точность 97%» без уточнения, с чем сравнение. Говорить: «95.4% с нашей разметкой, 97.3% со слепыми разметчиками».
- Не называть слепых разметчиков людьми или экспертами. Это AI-сессии.
- Не говорить «модель обучена». Мы ничего не дообучали.
- Не говорить, что тон «точный». Меток для тона нет.
- Не обещать работу внутри Dynamics 365 «из коробки». Не тестировали.
- Не обещать экономию в деньгах или часах. Данных нет.
- Не говорить «система детерминирована». Детерминированы подсчёт и кэш, модель — нет.
- Не называть цифры старых версий как текущие: $0.0011 и 91.4% — это v4, не v5.3.
- Не путать «held-out» с «никогда не видели». Говорить «отложенные, под них промпт не правили».
- Не выдавать ответ из кэша за живую оценку. SWAP и контроль с официальным чек-листом открываются из кэша: сказать об этом и нажать «Оценить заново».
- Не спорить с жюри о C7 и C2. Говорить: «следуем ответам организаторов, правило меняется в одном месте».

7. Чек-лист перед защитой

- Очистить данные сайта freedom-cqa.vercel.app в браузере демо-ноутбука (иначе старые ответы из прошлых тестов).
- Открыть заранее вкладки: лендинг, /admin/ (уже войти), README на GitHub, гайд PDF.
- Проверить интернет и /api/health (prompt_version eval-v5.3).
- Запасной план: локально `npm run dev` → http://localhost:3000/admin/ (код freedom); видео `landing-tair/assets/demo.mp4`; презентация `pitch/freedom-cqa-defense.pptx`.
- Решить, кто ведёт мышь, кто говорит. Отрепетировать с таймером один раз.
- Не обещать того, чего нет (см. «Чего не говорить»).

8. Ссылки и файлы

Продукт	https://freedom-cqa.vercel.app
Админка	https://freedom-cqa.vercel.app/admin/ · код freedom-agent
Клиентский чат	https://freedom-cqa.vercel.app/support/
Репозиторий	https://github.com/tairqaldy/doomdatathon-yatebyamognu
Гайд для жюри	docs/guide/freedom-cqa-guide.pdf
Презентация	pitch/freedom-cqa-defense.pptx · pitch/freedom-cqa-slides.pdf
Результаты	results/prod/results.json (10 FBroker) · results/dev/results.json (65 DEV)
Ответы жюри (полные)	pitch/jury-qa.md, 132 вопроса
Форма сдачи	https://forms.gle/Nz34xz4yK4XurwAt7

9. Кто за что отвечает

Тайр Калдыбаев	продукт вместе с Дамели: лендинг, поддержка, админка, интеграция, координация
Назар Аканов	оценщик, точность, gold, звонки и тон, контрольный прогон
Дамели Калиханова	продукт вместе с Тайром, ведущая по UX: рабочее место QA, админка, лендинг, README, озвучка видео
Амина Актаева	данные и хранилище, аудиты прозрачности и валидации