FREEDOM

NU Datathon 2026 · кейс Freedom Broker

Freedom CQA

Проверка качества каждого разговора оператора

Чаты и звонки на русском, казахском и английском. По каждому критерию: ответ, реплика-доказательство и балл, который считает код.

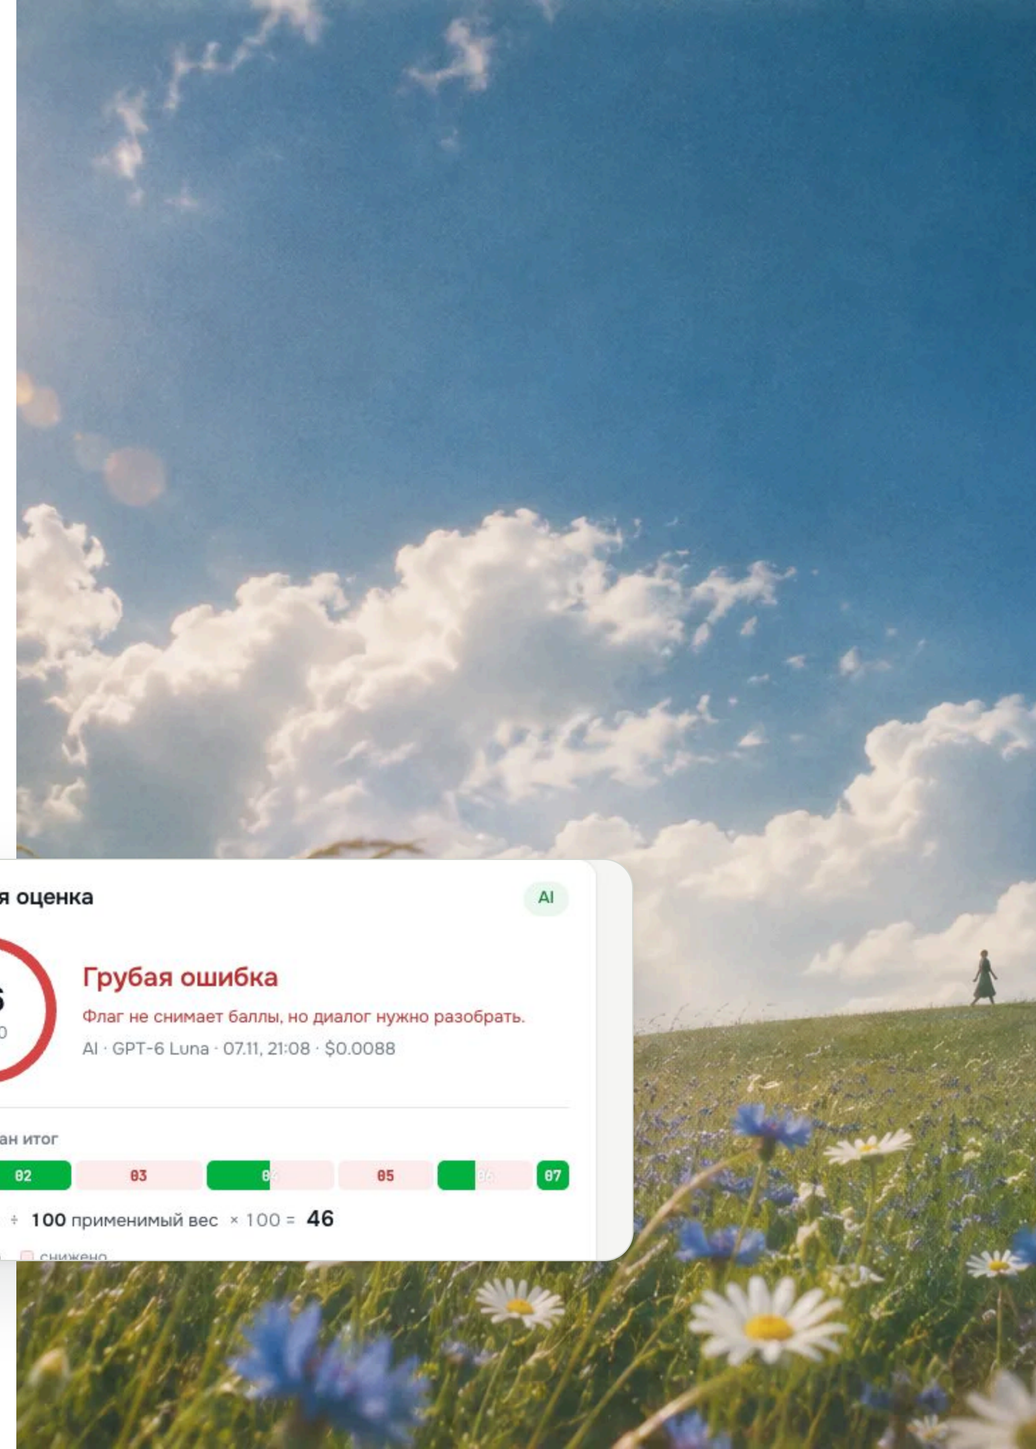
Команда **YaTebyaMognu**

Tair Kaldybayev
продукт, админка, исследование

Nazar Akanov
оценщик, разметка, метрики

Dameli Kalikhanova
UX рабочего места QA

Amina Aktayeva
хранилище, аудит расшифровок



Ручной контроль видит малую часть разговоров

2–5%

разговоров проверяют вручную в типичном контакт-центре

Оценки вендоров QA: Aircall, Enthu.AI

A ≠ B

Два проверяющих по-разному читают один и тот же критерий

Брифинг Freedom Broker на старте кейса

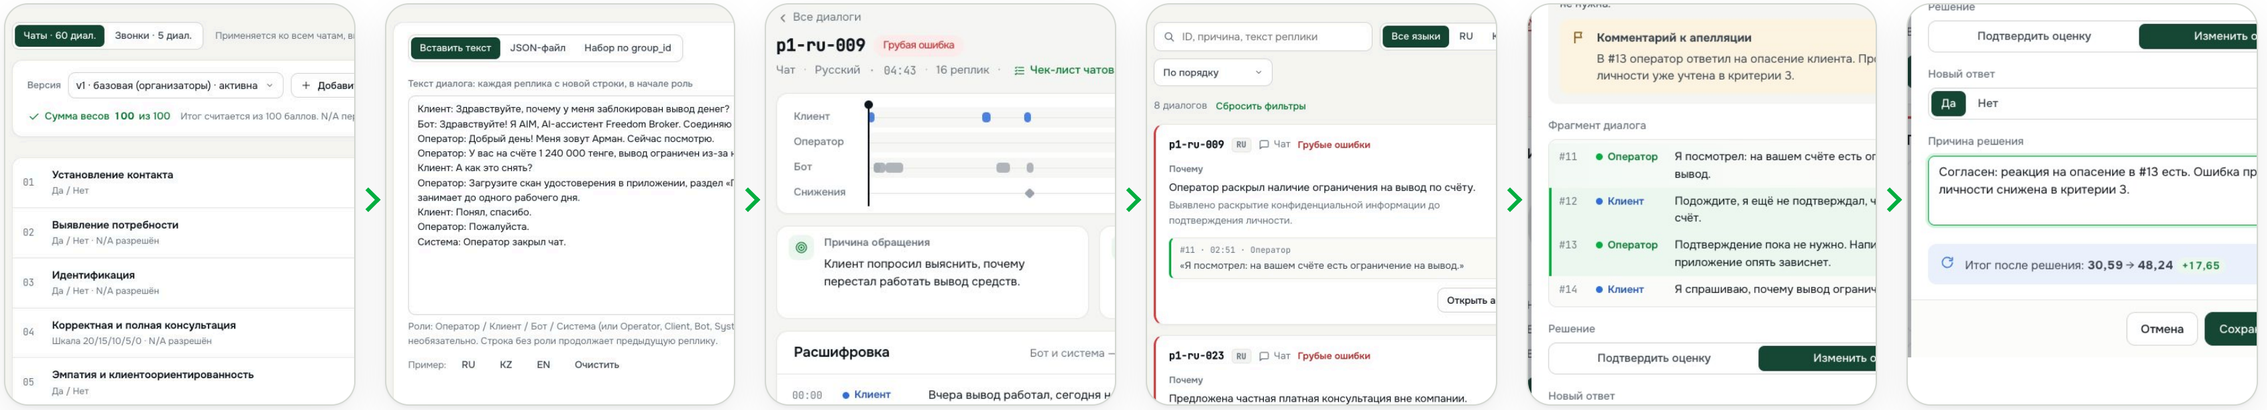
64%

клиентов предпочли бы поддержку без AI. Главный страх: не добраться до человека

Gartner, опрос 5 728 клиентов, 2024

Нужна регулярная проверка всего потока: с объяснением каждого балла и с последним словом за человеком.

Весь цикл контроля качества в одной админке



01

Чек-лист

Критерии, веса, шкалы и N/A: данные, а не код

02

Диалоги

Набор по group_id, вставка текста, живой чат

03

Оценка

Ответ и реплика-доказательство по каждому критерию

04

Результаты

Итог, причины снижения, грубые ошибки

05

Апелляция

Критерий, комментарий, фрагмент диалога

06

Переоценка

Проверяющий меняет ответ, итог пересчитан сразу

Изменили вес → итоги пересчитаны сразу

Изменили критерий → «Сохранить и переоценить» выбранные диалоги

Модель выбирает ответ и реплику. Баллы считает код.

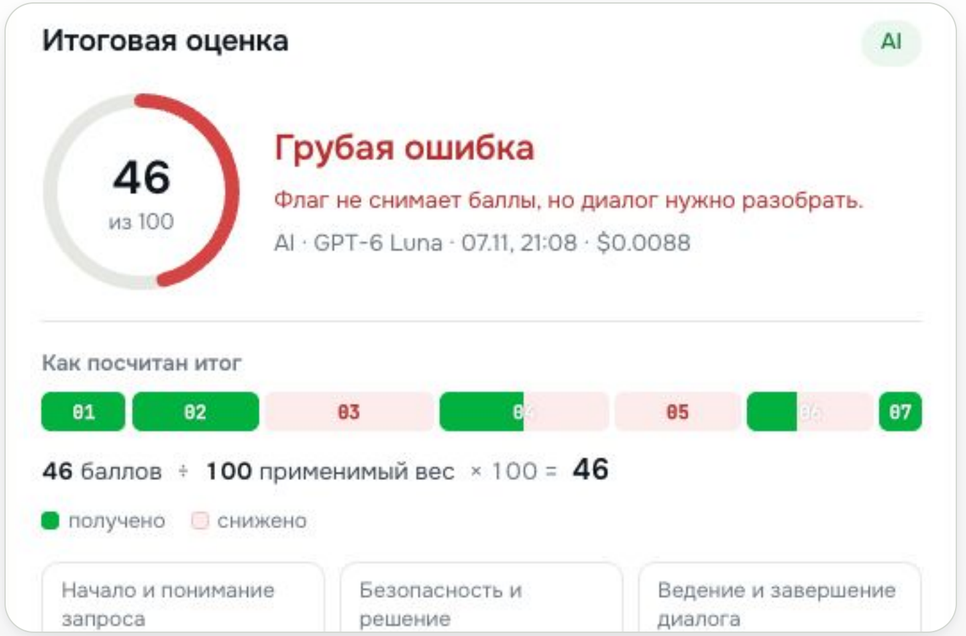
1 **Сначала факты**
Запрос, проверка личности, раскрытие данных, как закончился чат. Потом вердикт.

2 **3 прогона и голосование**
Большинство по каждому критерию. Карточка пишет «3 из 3» или «2 из 3 · проверьте».

3 **Цитата проверена**
Реплика существует, цитата совпадает. Нет доказательства: повторный запрос, а не выдуманный ответ.

4 **Баллы считает код**
Вес, шкала, перераспределение N/A, округление half-up до 2 знаков. Одна функция для UI, API и выгрузки.

! **Грубая ошибка отдельно**
Красный флаг с репликой. Баллы не снимает, диалог попадает в список на разбор.



Живой запрос к API: C3 = N/A, вес 20 выпадает; C7 = «нет», минус 5.
75 из 80 применимых → 93,75

Совпадение с разметкой по каждому ответу

95,4%

все 19 диалогов с эталонной разметкой, 152 ответа, строго

96,4%

отложенная часть: 7 диалогов, промпт под них не меняли

97,3%

независимая разметка: 2 слепых разметчика, 24 других чата, 185 ответов

7 / 7

грубых ошибок найдено, 0 ложных срабатываний

к Коэна **0,96** на 18 эталонных чатах (97,2%, 95% ДИ 93,1–98,9) · **0,97** по слепой разметке. Сами разметчики совпадают друг с другом на 96,4%.

Честно Эталон размечали мы, а не эксперты Freedom. Настоящий тест: **10 контрольных чатов**. Все 10 оценены, 0 ошибок, файл `results/prod/results.json`.

Дайте нам диалог: оценим при вас

/admin/#/import → «Вставить текст» →

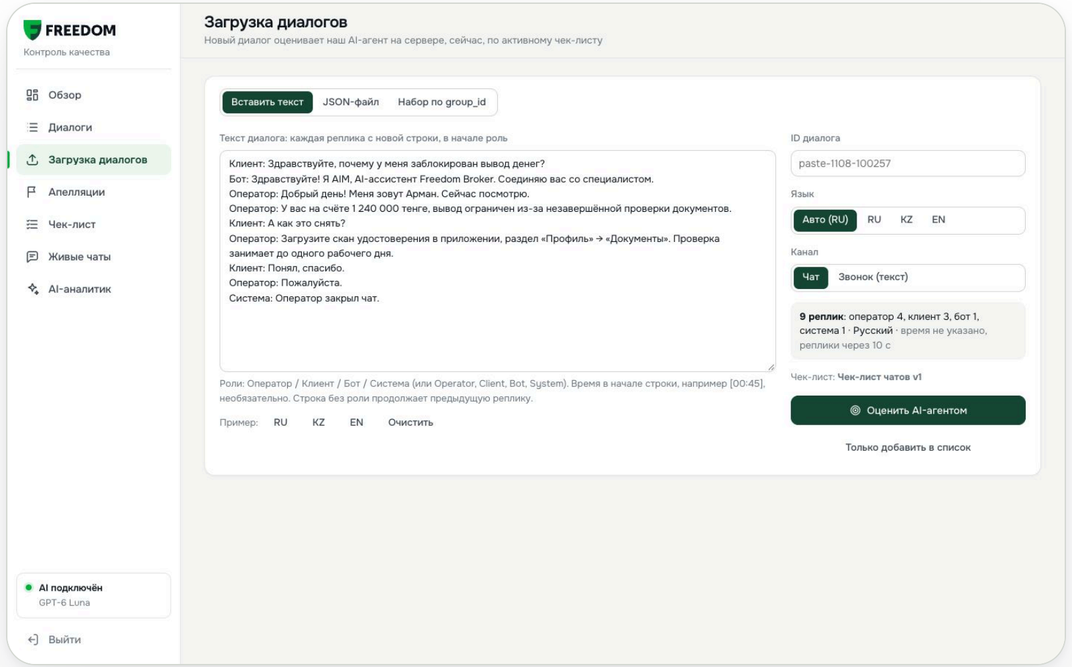
«Оценить AI-агентом»

Новый текст всегда уходит в модель, результат из кэша не подставляется. То же самое через `POST /api/evaluate`.

≈ 30 с
на чат, 3 прогона

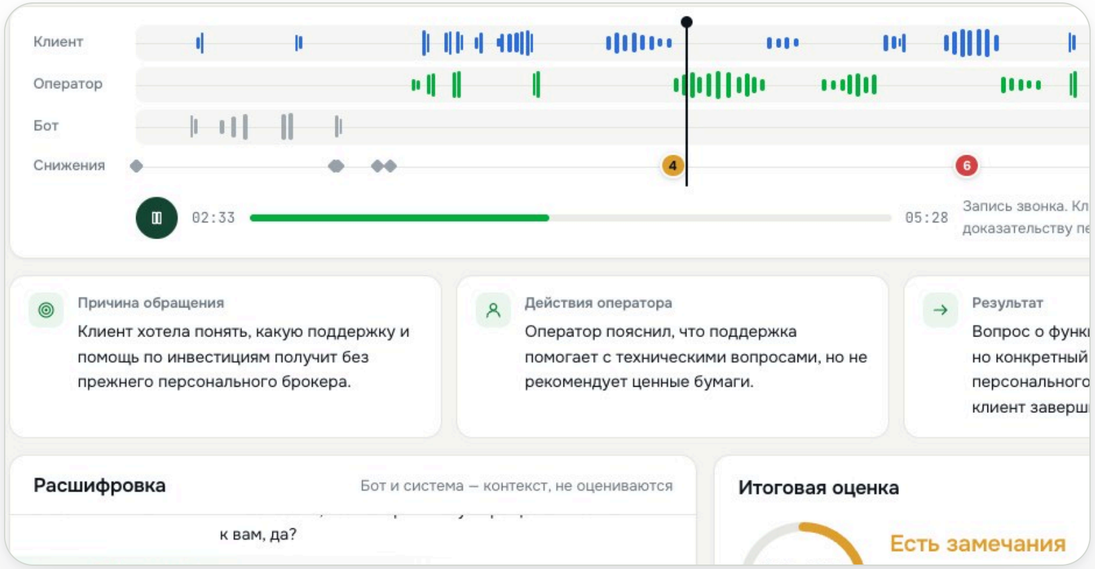
$0,006
на чат, все вызовы модели

≈ $70
за 10 000 диалогов



- **results/prod/results.json**: 10 контрольных чатов, формат JSON 1.0, проверен валидатором. $0,061 за весь набор.
- **results/dev/results.json**: все 65 DEV-диалогов, 60 чатов и 5 звонков.
- **Набор SWAP** (RU, KZ, EN) уже оценён: ответ из кэша приходит сразу, «Оценить заново» запускает свежий прогон.

Слышим звонок. Передаём клиента человеку.

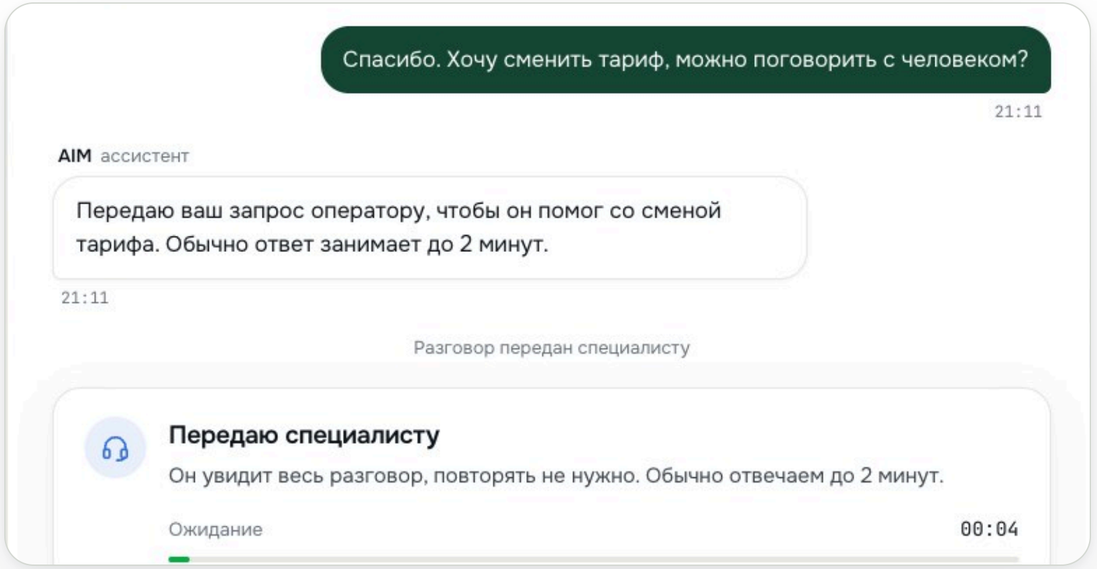


Звонки и тон голоса

Та же логика, адаптированная к речи. Клик по доказательству переносит плеер на нужную секунду. Критерий c09 «Тон и подача»: Gemini 3.8 Flash слушает запись и ставит 10, 7, 4 или 0.

5 реальных звонков DEV

≈ $0,016 за звонок



AIM и честная передача

AIM сразу говорит, что он AI. Не может помочь или клиент просит человека: передаёт оператору всю переписку, повторять не нужно. Разговор оператора потом проходит ту же проверку.

RU · KZ · EN

раскрытие бота: закон РК с 18.01.2026

Встраивается в контур Freedom

Dynamics 365

Спроектировано как HTML web resource: статические HTML, CSS и JS без сборки, монтируется в один элемент `#cqa-root`.

Чек-лист как данные

Критерии, веса, шкалы и правила N/A хранятся в JSON. Руководитель QA меняет их в интерфейсе.

API для любой CRM

`POST /api/evaluate`: на вход диалог и чек-лист, на выход ответы, объяснения и доказательства.

Формат JSON 1.0

Выгрузка результатов и независимый валидатор: все 8 критериев, номера реплик, пересчёт итога.

Кэш и Redis

Ключ кэша: модель, промпт, диалог, чек-лист. Повторный запрос бесплатен, общий кэш в Upstash Redis.

Своя модель

Любой OpenAI-совместимый сервер через `local:<model>`. Qwen 3.8 27B с открытыми весами: 94,1% на тех же метках.

Каждый разговор проверен. Каждый балл объяснён. Последнее слово за человеком.

Продукт

freedom-cqa.vercel.app

Админка /admin/ · код доступа

`freedom-agent`

Репозиторий

github.com/tairqaldy/doomdatathon-yatebyamognu

Спасибо Freedom Broker за кейс, данные и быстрые ответы, и клубу NU DataSci за датасон.